Document de travail

Propositions de plans

Attaques par injection de nœuds et robustesse des GNN

Présentation orale : 15 minutes • Démonstration : 5 minutes

Table des matières

1 Paradigmes d'optimisation **2**

1.1 Introduction et modélisation des GIA . . . 2
1.2 Attaques fondées sur les gradients . . . 2
1.3 Topologie et apprentissage séquentiel . . . 2
1.4 Défenses contre les injections . . . 2
1.5 Synthèse critique et démonstration . . . 2

2 Anatomie d'une injection : connexions et attributs **3**

2.1 Modèle de menace et propagation . . . 3
2.2 Choix des connexions : déterminer A_{inj} . . . 3
2.3 Choix des attributs : générer X_{inj} . . . 3
2.4 Détecter et neutraliser l'injection . . . 3
2.5 Synthèse et démonstration . . . 4

3 Évolution du domaine : la course aux armements **4**

3.1 Genèse : pourquoi injecter plutôt que modifier ? . . . 4
3.2 Première génération : discrétisation et passage à l'échelle . . . 4
3.3 Deuxième génération : évasion à grande échelle . . . 4
3.4 Riposte : exploiter les failles des attaques . . . 4
3.5 Troisième génération : furtivité, bilan et démonstration . . . 5

4 Propriétés des graphes : degré, homophilie, spectre et échelle **5**

4.1 Connectivité locale et modèle d'injection . . . 5
4.2 Degré et centralité dans les attaques . . . 5
4.3 Statistiques globales et optimisation séquentielle . . . 5
4.4 Homophilie et mécanismes de défense . . . 5
4.5 Synthèse multicritère et démonstration . . . 6

1. Paradigmes d'optimisation

Fil conducteur. Classer les attaques selon la façon dont elles résolvent le problème d'optimisation, puis examiner les défenses et les adaptations des attaquants.

1.1 Introduction et modélisation des GIA

3 min

— Rappeler le passage de messages dans les réseaux de neurones sur graphes (GNN) et expliquer la vulnérabilité créée par l'agrégation des voisinages.

— Comparer l'injection de nœuds (GIA) à la modification du graphe (GMA), en soulignant le réalisme de l'injection et sa formalisation par blocs à l'aide de A' et X'.

— Présenter les contraintes usuelles : budget de nœuds, degré maximal, et injection en une fois ou de manière séquentielle.

1.2 Attaques fondées sur les gradients

3 min

— Exposer le problème de discrétisation : l'ajout d'une arête est une décision binaire, alors que les méthodes d'optimisation opèrent souvent dans un espace continu.

— Présenter les premières approches gloutonnes, dont Greedy et Greedy-GAN, ainsi que leur coût de calcul.

— Expliquer la linéarisation du modèle substitut et l'approximation rapide fondée sur le signe du gradient, avec FGSM adapté et AFGSM, pour traiter des graphes de grande taille.

1.3 Topologie et apprentissage séquentiel

3 min

— Décrire la vulnérabilité topologique des nœuds de faible degré et l'exploitation de cette propriété pour sélectionner les arêtes d'injection dans TDGIA.

— Présenter l'optimisation sans dérivation directe par rapport au graphe, formulée comme un processus de décision markovien (MDP) et résolue par apprentissage par renforcement hiérarchique dans NIPA.

1.4 Défenses contre les injections

3 min

— Introduire la rupture de l'homophilie locale comme faiblesse exploitable par les attaques par injection.

— Comparer les mécanismes de filtrage fondés sur l'homophilie ou l'attention (GNNGuard, EGNNGuard et RGAT), qui peuvent écarter les arêtes suspectes.

— Présenter les méthodes qui stabilisent les représentations internes : RobustGCN, LayerNorm et l'entraînement contradictoire FLAG.

1.5 Synthèse critique et démonstration

3 min + 5 min de démonstration

— Montrer comment la régularisation d'homophilie HAO permet aux attaques de préserver leur discrétion et de contourner certaines défenses.

— Comparer les méthodes selon leur complexité et leur transférabilité entre architectures GNN.

— Conclure par une démonstration pratique d'injection et de défense.

2. Anatomie d'une injection : connexions et attributs

Fil conducteur. Décomposer une attaque en deux décisions techniques : où connecter les nœuds injectés (A_{inj}) et quels attributs leur attribuer (X_{inj}).

2.1 Modèle de menace et propagation

3 min

— Expliquer la vulnérabilité structurelle des GNN et distinguer la modification du graphe (GMA) de l'injection de nœuds (GIA).

— Définir les cadres d'attaque : empoisonnement (*poisoning*), notamment NIPA et AFGSM, ou évasion (*evasion*), notamment TDGIA et HAO ; distinguer également les attaques ciblées des attaques globales.

2.2 Choix des connexions : déterminer A_{inj}

3 min

— Comparer la connexion directe à la cible et la connexion indirecte par l'intermédiaire de ses voisins.

— Présenter les stratégies fondées sur les gradients de perte : Greedy, AFGSM et MetaGIA.

— Examiner les stratégies heuristiques et séquentielles : score de vulnérabilité topologique dans TDGIA et sélection d'actions par renforcement dans NIPA.

2.3 Choix des attributs : générer X_{inj}

3 min

— Comparer l'optimisation d'attributs continus, par descente de gradient projetée (PGD) ou optimisation lisse dans TDGIA, aux choix discrets fondés sur le signe du gradient.

— Traiter le réalisme des attributs à l'aide de contraintes de cooccurrence (AFGSM), d'un discriminateur adversaire (Greedy-GAN) et de la préservation de l'homophilie (HAO).

2.4 Détecter et neutraliser l'injection

3 min

— Expliquer pourquoi une injection naïve est plus facile à bloquer, notamment lorsqu'elle modifie la distribution d'homophilie.

— Décrire les défenses structurelles par élagage d'arêtes et seuil de similarité cosinus, comme GNNGuard et EGNNGuard.

— Comparer les défenses appliquées aux couches de convolution : normalisation (LayerNorm), distributions gaussiennes (RobustGCN) et architectures alternatives (SGCN, APPNP et TAGCN).

2.5 Synthèse et démonstration

3 min + 5 min de démonstration

— Construire une matrice de synthèse comparant puissance d'attaque, coût algorithmique et furtivité face aux défenses.

— Présenter le protocole expérimental et lancer la démonstration.

3. Évolution du domaine : la course aux armements

Fil conducteur. Raconter l'évolution des méthodes comme une succession d'attaques et de réponses défensives, depuis les premières attaques par modification jusqu'aux attaques furtives.

3.1 Genèse : pourquoi injecter plutôt que modifier ?

3 min

— Présenter les limites des premières attaques sur graphes, telles que Nettack, puis l'émergence des attaques par faux nœuds.

— Formaliser l'injection et expliquer l'effet théorique d'un nœud malveillant sur les couches de convolution d'un GNN.

3.2 Première génération : discrétisation et passage à l'échelle

3 min

— Présenter les approches pionnières d'empoisonnement : algorithmes gloutons (Greedy-GAN), Q-learning hiérarchique (NIPA) et linéarisation rapide (AFGSM).

— Comparer leur complexité algorithmique, de $O(n^2)$ à $O(n)$ selon les méthodes et les hypothèses considérées.

3.3 Deuxième génération : évasion à grande échelle

3 min

— Présenter le passage à des attaques en boîte noire au moment de l'inférence, sans réentraîner le GNN, illustré par le contexte du benchmark KDD Cup 2020.

— Expliquer TDGIA et son exploitation de la topologie pour maximiser l'impact avec une proportion réduite de nœuds injectés.

3.4 Riposte : exploiter les failles des attaques

3 min

— Comparer l'effet des GIA et des GMA sur l'homophilie du graphe, à partir des résultats théoriques et empiriques.

— Présenter les défenses fondées sur le filtrage de l'homophilie (GNNGuard), la variance (RobustGCN), la normalisation (LayerNorm) et l'entraînement robuste.

3.5 Troisième génération : furtivité, bilan et démonstration

3 min + 5 min de démonstration

— Expliquer comment l'objectif harmonieux HAO vise à préserver l'homophilie et à contourner les défenses.

— Présenter un tableau comparatif des méthodes, puis lancer la démonstration interactive.

4. Propriétés des graphes : degré, homophilie, spectre et échelle

Fil conducteur. Organiser l'exposé autour des propriétés structurelles qui déterminent la vulnérabilité des nœuds, la discrétion des injections et l'efficacité des défenses.

4.1 Connectivité locale et modèle d'injection

3 min

— Montrer comment la topologie locale influe sur les prédictions d'un GNN.

— Formaliser l'injection de nœuds et les budgets imposés à la structure du graphe.

4.2 Degré et centralité dans les attaques

3 min

— Analyser la vulnérabilité des nœuds en fonction de leur degré et expliquer pourquoi les nœuds de faible degré peuvent être plus sensibles.

— Examiner l'influence de la normalisation de la matrice d'adjacence, notamment la normalisation par ligne et la normalisation symétrique $\tilde{D}^{-1/2}\tilde{A}\tilde{D}^{-1/2}$.

— Relier ces propriétés aux méthodes TDGIA et AFGSM.

4.3 Statistiques globales et optimisation séquentielle

3 min

— Étudier les moyens de limiter les changements à la loi de puissance des degrés, au nombre de composantes connexes et au nombre de triangles, notamment dans NIPA et Greedy-GAN.

— Comparer l'optimisation globale à l'ajout séquentiel des nœuds injectés.

4.4 Homophilie et mécanismes de défense

3 min

— Définir l'homophilie centrée sur les nœuds et l'homophilie centrée sur les arêtes.

— Présenter les défenses fondées sur la restauration de l'homophilie (GNNGuard et élagage par similarité cosinus) ainsi que la régularisation des représentations (LayerNorm et RobustGCN).

— Examiner le contournement de ces défenses par la contrainte d'homophilie HAO.

4.5 Synthèse multicritère et démonstration

3 min + 5 min de démonstration

— Récapituler les compromis entre attaques et défenses, sur des graphes de petite et de grande taille.

— Présenter et lancer une démonstration pratique sur le jeu de données Cora.